

# 项目实战——利用 PyTorch 构建 RNN模型

---

本文将通过一个实战项目带大家使用PyTorch 搭建 RNN 模型。

本项目将构建一个 RNN 模型，来对 MNIST 手写数据集进行分类。可能有同学会有疑问，MNIST 数据集不是图片吗，而 RNN 是处理序列信号的。为什么图片识别也能使用 RNN 模型呢？其实，这里我们可以把图片看成是序列信号，例如下面是 MNIST 数据集的一张图片：



MNIST 数据集中所有的图片都是 28x28 的。按行来看，图片的每一行都包含 28 个像素点，一共有 28 行。因此，我们可以把每一行的 28 个像素点当成 RNN 的一个输入  $\mathbf{x}^{<t>}$ 。总共有 28 行，则  $T_{\mathbf{x}} = 28$ 。图片的分割方式如下图所示：



输入已经确定了，对于输出，因为是分类问题，识别 0~9 数字，因此，RNN 模型应该有 10 个输出，即  $T_y = 10$ 。此例中， $T_x \neq T_y$ 。

确定了基本结构和输入输出之后，我们开始使用 PyTorch 构建 RNN。首先，还是导入 MNIST 数据集。

## 导入数据集

下面代码实现了 MNIST 数据集的导入。

```
1. import torch
2. import torchvision
3. import torchvision.transforms as transforms
4. import torch.nn as nn
5. import torch.nn.functional as F
6. import torch.optim as optim
7. import matplotlib.pyplot as plt
8. import numpy as np
9.
10. transform = transforms.Compose(
11.     [transforms.ToTensor()])
12.
13. # 训练集
14. trainset = torchvision.datasets.MNIST(root='./data',          # 选择数据的根目录
15.                                     train=True,
```

```

16.                                     download=False,      # 不从网络上download
    load图片
17.                                     transform=transform)
18. trainloader = torch.utils.data.DataLoader(trainset, batch_size=4,
19.                                           shuffle=True, num_workers=2)
20. # 测试集
21. testset = torchvision.datasets.MNIST(root='./data',      # 选择数据的根目
    录
22.                                     train=False,
23.                                     download=False,      # 不从网络上download
    load图片
24.                                     transform=transform)
25. testloader = torch.utils.data.DataLoader(testset, batch_size=4,
26.                                           shuffle=False, num_workers=2)

```

上述代码中，我们也可以设置 `download=True`，表示在线下载数据集。因为我已提前下载完成，这里的 `download` 设置为 `False`，即从本地导入数据集。我们设置 `batch_size=4`，`shuffle=True` 表示每次 epoch 都重新打乱训练样本，`num_workers=2` 表示使用两个子进程加载数据。


下面程序展示了 Mini-batch 训练样本图片并标注正确标签的过程。

```

1. def imshow(img):
2.     npimg = img.numpy()
3.     plt.imshow(np.transpose(npimg, (1, 2, 0)))
4.
5. # 选择一个 batch 的图片
6. dataiter = iter(trainloader)
7. images, labels = dataiter.next()
8.
9. # 显示图片
10. imshow(torchvision.utils.make_grid(images))
11. plt.show()
12. # 打印 labels
13. print(' '.join('%11s' % labels[j].numpy() for j in range(4)))

```

运行结果，如下图所示：



我们可以来看一下训练集和测试集的维度。

```
1. print(trainset.train_data.size())
2. print(testset.test_data.size())
```

运行结果如下：

```
torch.Size([60000, 28, 28])
torch.Size([10000, 28, 28])
```

训练集包含 60000 张图片，测试集包含 10000 张图片，每张图片大小为 28x28。

## 定义 RNN 模型

与 CNN 类似，我们可以使用 PyTorch 直接搭建 RNN 模型，首先定义 RNN 类。

```
1. class Net(nn.Module):
2.     def __init__(self):
3.         super(Net, self).__init__()
4.         self.rnn = nn.LSTM(                # 使用 LSTM 结构
5.             input_size = 28,                # 输入每个元素的维度，即图片每行包含 28
           个像素点
6.             hidden_size = 84,                # 隐藏层神经元设置为 84 个
7.             num_layers=1,                    # 隐藏层数目，单层
8.             batch_first=True,                # 是否将 batch 放在维度的第一位，(batch
           数字
9.             h, time_step, input_size)
10.         self.out = nn.Linear(84, 10) # 输出层，包含 10 个神经元，对应 0~9
11.
```

```

12.         def forward(self, x):
13.             r_out, (h_n, h_c) = self.rnn(x, None)
14.             # 选择图片的最后一行作为 RNN 输出
15.             out = self.out(r_out[:, -1, :])
16.             return out

```

以上代码是构建 RNN 的核心部分。我们发现 PyTorch 中构建 RNN 模型非常简单，只需简单的几行语句。下面对上面的部分代码做下重点讲解。

代码中 `input_size = 28` 表示每个输入元素  $x^{<t>}$  的维度，即图片每行包含 28 个像素点。`hidden_size = 84` 将隐藏层神经元设置为 84 个，`num_layers=2` 表示有两层隐藏层。`self.out = nn.Linear(84, 10)` 表示输出层，输出为 0~9 数字。

`r_out, (h_n, h_c) = self.rnn(x, None)` 中，`(h_n, h_c)` 为 LSTM 的记忆单元，`r_out` 为输出，每个  $x^{<t>}$  的输出都会累加在 `r_out` 中。`None` 表示最初的隐藏层记忆单元为 0。`out = self.out(r_out[:, -1, :])` 表示选择图片最后一行的结果作为输出。

接下来我们可以建立一个 Net 对象，并打印出来，看看其网络结构。

```

1. net = Net()
2. print(net)

```

运行结果，如下：

```

1. Net(
2.   (rnn): LSTM(28, 84, num_layers=2, batch_first=True)
3.   (out): Linear(in_features=84, out_features=10, bias=True)
4. )

```

非常直观，可以完整清晰地查看我们构建的 RNN 模型结构。

## 定义损失函数

正如之前利用 PyTorch 构建 CNN 模型的实战过程，我们仍使用 Adam 梯度优化算法，即：

```
1. criterion = nn.CrossEntropyLoss()
2. optimizer = optim.Adam(net.parameters(), lr=0.0001)
```

## 训练网络

接下来就是最有趣的地方了。我们只需循环遍历数据迭代器，放入网络的输入层并优化即可。

```
1. num_epochs = 5      # 设置 epoch 数目
2. cost = []           # 损失函数累加
3.
4. for epoch in range(num_epochs):
5.
6.     running_loss = 0.0
7.     for i, data in enumerate(trainloader, 0):
8.         # 输入样本和标签
9.         inputs, labels = data
10.        inputs = inputs.view(-1, 28, 28) # 设置 RNN 输入维度为 (batch, time_step, input_size)
11.
12.        # 每次训练梯度清零
13.        optimizer.zero_grad()
14.
15.        # 正向传播、反向传播和优化过程
16.        outputs = net(inputs)
17.        loss = criterion(outputs, labels)
18.        loss.backward()
19.        optimizer.step()
20.
21.        # 打印训练情况
22.        running_loss += loss.item()
23.        if i % 2000 == 1999:      # 每隔2000 mini-batches, 打印一次
24.            print('[%d, %5d] loss: %.3f' %
25.                  (epoch + 1, i + 1, running_loss / 2000))
26.            cost.append(running_loss / 2000)
27.            running_loss = 0.0
```

上述代码中需要注意的是，每次迭代训练时都要先把所有梯度清零，即

`optimizer.zero_grad()`。否则，梯度会累加，造成训练错误和失效。PyTorch 中的

`.backward()` 能自动完成所有梯度计算。我们发现，PyTorch 中 RNN 的训练代码与 CNN

十分类似，只不过 RNN 的输入维度由 `inputs = inputs.view(-1, 28, 28)` 语句重新设置

为 `(batch, time_step, input_size)` , 即 `(4, 28, 28)` 。


打印的结果如下：

```
1.    [1,  2000] loss: 1.594
2.    [1,  4000] loss: 0.772
3.    [1,  6000] loss: 0.528
4.    [1,  8000] loss: 0.425
5.    [1, 10000] loss: 0.362
6.    [1, 12000] loss: 0.287
7.    [1, 14000] loss: 0.276
8.    [2,  2000] loss: 0.221
9.    [2,  4000] loss: 0.206
10.   [2,  6000] loss: 0.214
11.   [2,  8000] loss: 0.189
12.   [2, 10000] loss: 0.187
13.   [2, 12000] loss: 0.165
14.   [2, 14000] loss: 0.157
15.   [3,  2000] loss: 0.155
16.   [3,  4000] loss: 0.135
17.   [3,  6000] loss: 0.129
18.   [3,  8000] loss: 0.125
19.   [3, 10000] loss: 0.122
20.   [3, 12000] loss: 0.126
21.   [3, 14000] loss: 0.111
22.   [4,  2000] loss: 0.103
23.   [4,  4000] loss: 0.100
24.   [4,  6000] loss: 0.097
25.   [4,  8000] loss: 0.100
26.   [4, 10000] loss: 0.094
27.   [4, 12000] loss: 0.101
28.   [4, 14000] loss: 0.098
29.   [5,  2000] loss: 0.087
30.   [5,  4000] loss: 0.083
31.   [5,  6000] loss: 0.073
32.   [5,  8000] loss: 0.082
33.   [5, 10000] loss: 0.090
34.   [5, 12000] loss: 0.080
35.   [5, 14000] loss: 0.072
```

将所有 Loss 趋势绘制成图，如下所示：

```
1.    plt.plot(cost)
```

```
2. plt.ylabel('cost')
3. plt.show()
```



显然，随着迭代训练，Loss 逐渐减小。

## 测试数据

让我们来看一下网络模型在整个测试数据集上的训练效果。

```
1. correct = 0
2. total = 0
3. with torch.no_grad():
4.     for data in testloader:
5.         images, labels = data
6.         images = images.view(-1, 28, 28)
7.         outputs = net(images)
8.         _, predicted = torch.max(outputs.data, 1)
9.         total += labels.size(0)
10.        correct += (predicted == labels).sum().item()
11.
12. print('Accuracy of the network on the 10000 test images: %.3f %%' %
13.       (100 * correct / total))
```

执行结果如下：

Accuracy of the network on the 10000 test images: 97.790 %



结果显示模型在测试集上的准确率达到了 97.790 %。说明我们训练的 RNN 模型性能还是不错的。